ĐẠI HỌC QUỐC GIA, THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA

HỌC MÁY - CO3117

BÁO CÁO BÀI TẬP LỚN

PIPELINE HỌC MÁY - L01 - NHÓM 8

GVHD:	Th.S Trương Vĩnh Lân	
SV thực hiện:	Đặng Đình Minh Hoàng	2411068
	Nguyễn Ngọc Thành Đạt	2111013
	Phạm Minh Đức	2414106
	Ngô Đức Thắng	2313184
	Nguyễn Hữu Khánh	2211521

TP Hồ Chí Minh, Tháng 5 Năm 2026

Mục lục

TÓM TẮT **3**

1. Tổng quan về Dataset **4**
a. Giới thiệu về bộ dữ liệu 4
b. Nguồn dữ liệu 4
c. Cấu trúc dữ liệu 4
d. Ý nghĩa các lớp nhãn 5
e. Nhận xét tổng quan về bộ dữ liệu 5

2. EDA - Phân tích khai phá dữ liệu **7**
a. Phân phối nhãn 7
b. Phân phối độ dài văn bản 7
c. Phân tích từ khóa theo từng lớp 9
d. Phân tích tần suất từ phổ biến 11
e. Nhận xét tổng hợp 12

3. Pipeline học máy truyền thống **13**
a. Tiền xử lý dữ liệu 13
b. Trích xuất đặc trưng 14
c. Huấn luyện và đánh giá mô hình 16
d. So sánh trực quan giữa các mô hình 18

4. Pipeline học sâu (Deep Learning) **21**
a. Tiền xử lý và trích xuất đặc trưng 21
b. Huấn luyện và đánh giá mô hình 23

5. So sánh giữa hai pipeline **28**

6. Tổ chức và quản lý mã nguồn của nhóm **32**

TÀI LIỆU THAM KHẢO **35**

Bảng phân công và đánh giá mức độ hoàn thành

Họ tên	**MSSV**	**Công việc**	**Tỉ lệ hoàn thành**	**Nhận xét của thầy**
Đặng Đình Minh Hoàng	2411141	Tổng hợp nội dung & Huấn luyện mô hình	100%	
Nguyễn Ngọc Thành Đạt	2111013	Trích xuất đặc trưng	100%	
Phạm Minh Đức	2414106	Đánh giá mô hình	100%	
Ngô Đức Thắng	2313184	EDA	100%	
Nguyễn Hữu Khánh	2211521	Tiền xử lý dữ liệu	100%	

TÓM TẮT

Báo cáo bài tập lớn này trình bày quá trình xây dựng và đánh giá hệ thống phân loại văn bản đa lớp trên bộ dữ liệu **AG News Classification Dataset**. Đây là bộ dữ liệu gồm các bản tin thuộc bốn chủ đề chính: *World*, *Sports*, *Business* và *Sci/Tech*. Mục tiêu của bài toán là xây dựng mô hình học máy có khả năng dự đoán chính xác chủ đề của một văn bản tin tức đầu vào. Trong quá trình thực hiện, nhóm sử dụng tập huấn luyện gồm 120000 mẫu và tập kiểm tra gồm 7600 mẫu để đánh giá hiệu quả của các phương pháp.

Nhóm triển khai hai hướng tiếp cận chính: pipeline học máy truyền thống và pipeline học sâu. Đối với pipeline truyền thống, dữ liệu văn bản được tiền xử lý thông qua các bước làm sạch văn bản, chuẩn hóa nội dung, loại bỏ stopwords và biến đổi văn bản thành biểu diễn số. Hai phương pháp trích xuất đặc trưng được sử dụng là **Bag of Words** và **TF-IDF**, với số lượng đặc trưng được giới hạn nhằm đảm bảo hiệu quả tính toán. Các vector đặc trưng sau đó được đưa vào các mô hình phân loại truyền thống gồm **Naive Bayes**, **Logistic Regression** và **Linear Support Vector Machine**.

Bên cạnh đó, nhóm thực hiện thêm pipeline học sâu nhằm so sánh với hướng tiếp cận truyền thống. Trong pipeline này, mô hình ngôn ngữ **DistilBERT** được sử dụng để trích xuất các vector embedding có khả năng biểu diễn ngữ nghĩa của văn bản. Các embedding thu được có kích thước 768 chiều và được lưu lại dưới định dạng `.npy` để tái sử dụng trong quá trình huấn luyện. Sau đó, nhóm sử dụng mô hình **MLP Neural Network** để phân loại văn bản dựa trên các đặc trưng học sâu đã trích xuất.

Kết quả thực nghiệm cho thấy pipeline học sâu đạt hiệu quả tốt nhất với mô hình **MLP Neural Network** sử dụng đặc trưng **DistilBERT Embedding**, đạt **Accuracy** khoảng **91.42%**, **Macro F1** khoảng **91.42%** và **Weighted F1** khoảng **91.42%**. Trong pipeline truyền thống, mô hình tốt nhất là **Linear SVM** kết hợp với đặc trưng **Bag of Words**, đạt **Accuracy** khoảng **90.87%** và **Macro F1** khoảng **90.85%**. Kết quả này cho thấy đặc trưng học sâu từ DistilBERT giúp cải thiện hiệu năng phân loại so với các phương pháp biểu diễn văn bản truyền thống, tuy nhiên chi phí huấn luyện và xử lý cũng cao hơn.

Thông qua quá trình thực nghiệm, báo cáo phân tích và so sánh hiệu quả của các mô hình dựa trên các chỉ số **Accuracy**, **Precision**, **Recall**, **Macro F1** và **Weighted F1**. Từ đó, nhóm rút ra nhận xét về ưu điểm, hạn chế của từng pipeline và đánh giá mức độ phù hợp của các phương pháp học máy truyền thống và học sâu đối với bài toán phân loại văn bản tin tức.

1. Tổng quan về Dataset

a. Giới thiệu về bộ dữ liệu

Trong bài tập lớn này, nhóm sử dụng bộ dữ liệu **AG News Classification Dataset** cho bài toán phân loại văn bản đa lớp. Đây là bộ dữ liệu gồm các bản tin ngắn được thu thập từ nhiều nguồn tin tức khác nhau. Mỗi mẫu dữ liệu bao gồm tiêu đề tin tức, phần mô tả ngắn và nhãn chủ đề tương ứng.

Bài toán đặt ra là xây dựng mô hình học máy có khả năng dự đoán chính xác chủ đề của một văn bản tin tức đầu vào. Cụ thể, mỗi văn bản sẽ được phân loại vào một trong bốn nhóm chủ đề: *World*, *Sports*, *Business* và *Sci/Tech*. Đây là một bài toán phân loại văn bản có giám sát, trong đó dữ liệu đầu vào là văn bản tự nhiên và đầu ra là nhãn lớp tương ứng.

b. Nguồn dữ liệu

Bộ dữ liệu được tải trực tiếp từ nguồn công khai AG News thông qua thư viện `kagglehub` trong Google Colab. Việc sử dụng nguồn dữ liệu công khai giúp notebook có thể tự động tải dữ liệu khi chạy lại từ đầu phù hợp với yêu cầu của bài tập lớn.

Trong quá trình xử lý, dữ liệu được chia sẵn thành hai tập:

- **Tập huấn luyện**: dùng để huấn luyện các mô hình học máy.
- **Tập kiểm tra**: dùng để đánh giá hiệu quả phân loại của các mô hình sau khi huấn luyện.

c. Cấu trúc dữ liệu

Mỗi mẫu dữ liệu ban đầu gồm ba trường chính:

- **label**: nhãn chủ đề của văn bản, được mã hóa bằng số từ 1 đến 4.
- **title**: tiêu đề của bản tin.
- **description**: phần mô tả ngắn của bản tin.

Để phục vụ quá trình huấn luyện mô hình, nhóm tạo thêm cột **text** bằng cách ghép hai trường **title** và **description**. Cột này được sử dụng làm dữ liệu văn bản đầu vào cho các bước tiền xử lý và trích xuất đặc trưng.

Table 1: Thống kê tổng quan bộ dữ liệu AG News

Thuộc tính	**Giá trị**
Tên bộ dữ liệu	AG News Classification Dataset
Loại dữ liệu	Văn bản tin tức
Dạng bài toán	Phân loại văn bản đa lớp
Số lớp phân loại	4
Các lớp nhãn	World, Sports, Business, Sci/Tech
Số mẫu tập huấn luyện	120000
Số mẫu tập kiểm tra	7600
Tổng số mẫu	127600
Số mẫu mỗi lớp trong tập huấn luyện	30000
Số mẫu mỗi lớp trong tập kiểm tra	1900
Các trường dữ liệu gốc	label, title, description
Trường dữ liệu được tạo thêm	text, label_name
Số giá trị thiếu trong tập huấn luyện	0
Số giá trị thiếu trong tập kiểm tra	0
Số dòng trùng lặp trong tập huấn luyện	0
Số dòng trùng lặp trong tập kiểm tra	0
Độ dài văn bản trung bình	37.84 từ
Độ dài văn bản trung vị	37 từ
Độ dài văn bản ngắn nhất	4 từ
Độ dài văn bản dài nhất	177 từ

d. Ý nghĩa các lớp nhãn

Bộ dữ liệu gồm bốn lớp nhãn chính, tương ứng với bốn nhóm chủ đề tin tức khác nhau. Bảng dưới đây mô tả ý nghĩa của từng nhãn trong bộ dữ liệu.

Table 2: Mô tả các lớp nhãn trong bộ dữ liệu

Nhãn	**Tên lớp**	**Mô tả**
1	World	Các tin tức liên quan đến thế giới, chính trị, xã hội và sự kiện quốc tế.
2	Sports	Các tin tức liên quan đến thể thao, giải đấu, vận động viên và kết quả thi đấu.
3	Business	Các tin tức liên quan đến kinh tế, tài chính, doanh nghiệp, thị trường và thương mại.
4	Sci/Tech	Các tin tức liên quan đến khoa học, công nghệ, nghiên cứu và sản phẩm kỹ thuật.

e. Nhận xét tổng quan về bộ dữ liệu

Bộ dữ liệu AG News có quy mô tương đối lớn với tổng cộng 127600 mẫu, trong đó tập huấn luyện gồm 120000 mẫu và tập kiểm tra gồm 7600 mẫu. Dữ liệu được phân bố cân bằng giữa bốn lớp, với 30000 mẫu cho mỗi lớp trong tập huấn luyện và 1900 mẫu cho mỗi lớp trong tập kiểm tra. Điều này giúp quá trình huấn luyện mô hình ít bị ảnh hưởng bởi hiện tượng mất cân bằng lớp.

Ngoài ra, dữ liệu không có giá trị thiếu và không có dòng trùng lặp trong cả tập huấn luyện

lẫn tập kiểm tra. Đây là một đặc điểm thuận lợi cho quá trình xây dựng pipeline học máy, vì nhóm không cần thực hiện các bước xử lý phức tạp đối với dữ liệu thiếu hoặc dữ liệu lặp.

Về độ dài văn bản, mỗi mẫu tin tức có độ dài trung bình khoảng 37.84 từ và trung vị là 37 từ. Điều này cho thấy phần lớn văn bản trong bộ dữ liệu là các bản tin ngắn, phù hợp với các phương pháp biểu diễn văn bản như **Bag of Words**, **TF-IDF** và các mô hình embedding hiện đại như **DistilBERT**. Với đặc điểm này, bộ dữ liệu phù hợp để so sánh giữa pipeline học máy truyền thống và pipeline học sâu trong bài toán phân loại văn bản.

2. EDA - Phân tích khai phá dữ liệu

a. Phân phối nhãn

Hình 1 thể hiện phân phối nhãn của tập huấn luyện. Có thể thấy bốn lớp *World*, *Sports*, *Business* và *Sci/Tech* đều có số lượng mẫu bằng nhau, mỗi lớp gồm 30000 mẫu.

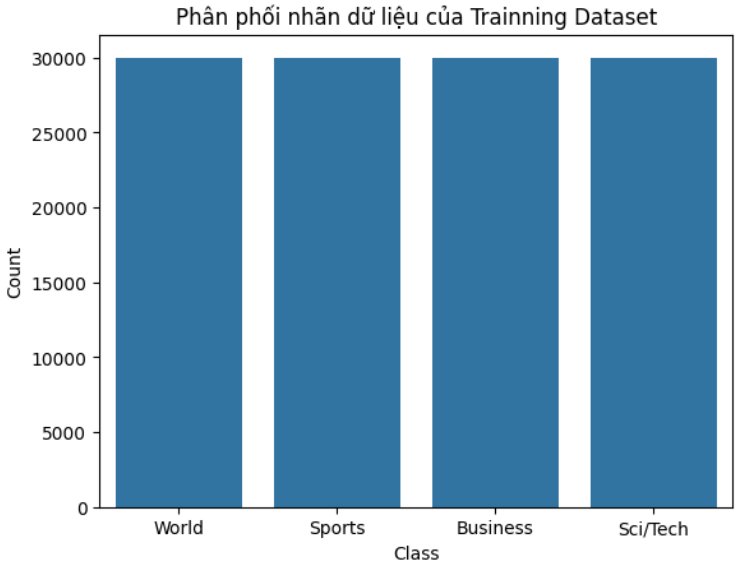

Figure 1: Phân phối nhãn dữ liệu của tập huấn luyện

Phân phối nhãn cân bằng là một đặc điểm thuận lợi cho quá trình huấn luyện mô hình. Khi số lượng mẫu giữa các lớp tương đương nhau, mô hình ít có xu hướng thiên lệch về một lớp chiếm đa số. Do đó, chỉ số *accuracy* có thể phản ánh tương đối tốt hiệu quả phân loại tổng thể. Tuy nhiên, nhóm vẫn sử dụng thêm các chỉ số như *precision*, *recall*, *macro F1* và *weighted F1* để đánh giá mô hình một cách toàn diện hơn.

b. Phân phối độ dài văn bản

Độ dài văn bản được tính dựa trên số lượng từ trong mỗi mẫu sau khi ghép tiêu đề và phần mô tả. Hình 2 cho thấy phân phối độ dài văn bản theo từng lớp.

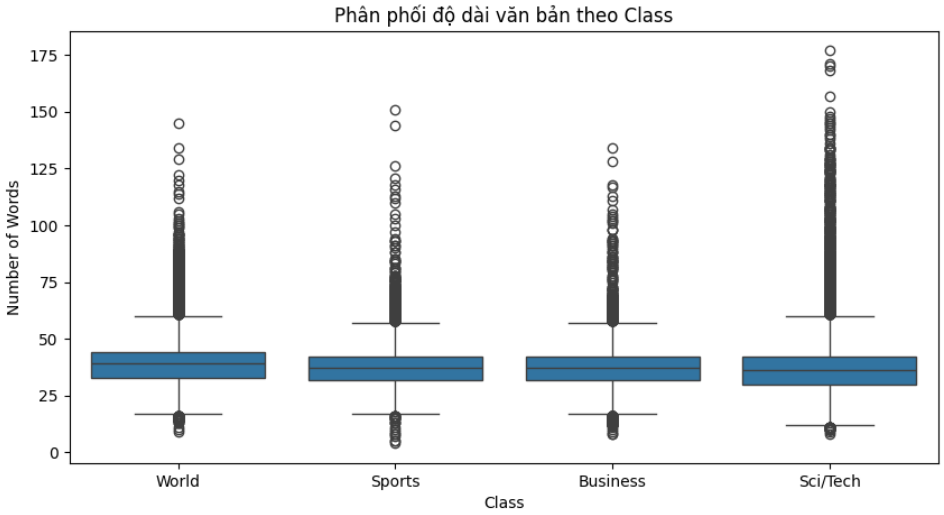

Figure 2: Phân phối độ dài văn bản theo từng lớp

Từ biểu đồ boxplot, có thể thấy độ dài văn bản giữa bốn lớp tương đối giống nhau. Phần lớn các văn bản có độ dài tập trung quanh khoảng 30 đến 45 từ. Trung vị của các lớp không có sự chênh lệch quá lớn, cho thấy độ dài văn bản không phải là yếu tố gây khác biệt mạnh giữa các nhóm chủ đề. Tuy nhiên, vẫn tồn tại một số giá trị ngoại lai, đặc biệt ở lớp *Sci/Tech*, với một số văn bản có độ dài vượt quá 150 từ. Điều này cho thấy trong dữ liệu có một số bản tin dài hơn đáng kể so với phần lớn các mẫu còn lại.

Hình 3 thể hiện phân phối độ dài văn bản trên toàn bộ tập huấn luyện.

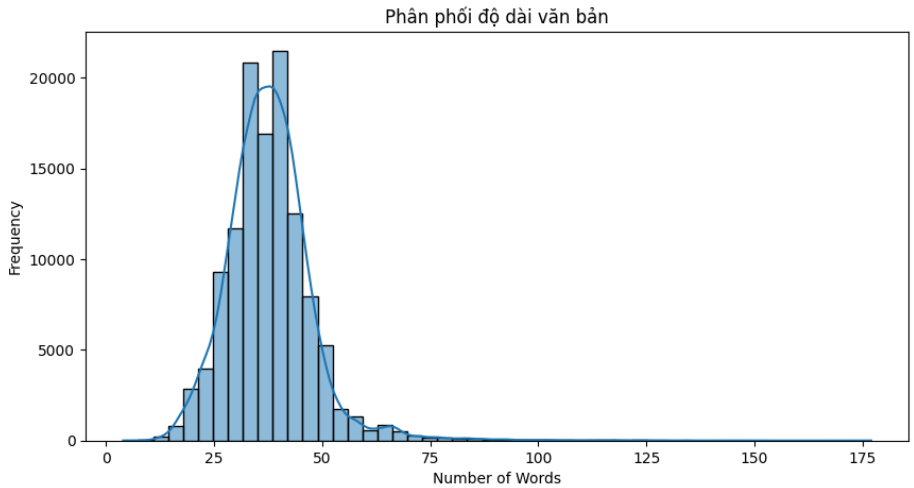

Figure 3: Phân phối độ dài văn bản trong tập huấn luyện

Phân phối độ dài văn bản có dạng lệch phải. Phần lớn văn bản có độ dài nằm trong khoảng 25 đến 50 từ, trong khi số lượng văn bản dài hơn 75 từ khá ít. Điều này phù hợp với đặc điểm của bộ dữ liệu AG News, trong đó mỗi mẫu thường là một bản tin ngắn gồm tiêu đề và đoạn

mô tả tóm tắt. Kết quả này cho thấy các phương pháp biểu diễn văn bản như Bag of Words và TF-IDF có thể hoạt động hiệu quả vì văn bản tương đối ngắn, ít chịu ảnh hưởng bởi cấu trúc ngữ cảnh dài. Đồng thời, khi sử dụng mô hình học sâu như DistilBERT, việc giới hạn chiều dài chuỗi đầu vào ở một giá trị vừa phải vẫn có thể bao phủ phần lớn dữ liệu.

c. Phân tích từ khóa theo từng lớp

Để quan sát trực quan các từ xuất hiện nổi bật trong từng lớp, nhóm sử dụng biểu đồ WordCloud cho bốn nhóm chủ đề. Kích thước của mỗi từ trong WordCloud phản ánh tần suất xuất hiện tương đối của từ đó trong lớp tương ứng.

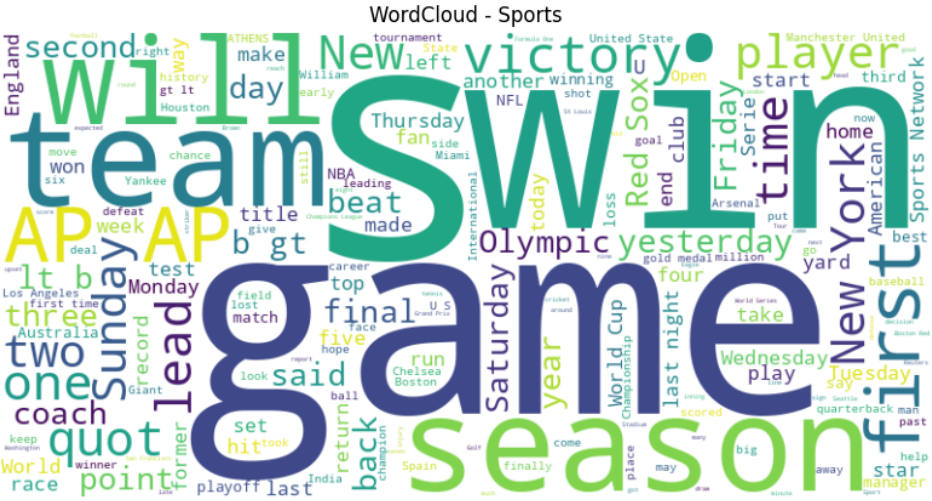

Figure 4: WordCloud của lớp Sports

Đối với lớp *Sports*, các từ nổi bật gồm *game*, *team*, *win*, *season*, *player*, *coach* và *Olympic*. Đây là các từ có liên quan trực tiếp đến thể thao, trận đấu, đội tuyển và kết quả thi đấu. Điều này cho thấy lớp *Sports* có đặc trưng từ vựng khá rõ ràng, giúp các mô hình truyền thống như Bag of Words, TF-IDF và Linear SVM có khả năng phân loại tốt.

Figure 5: WordCloud của lớp World

Đối với lớp *World*, các từ xuất hiện nhiều gồm *Iraq*, *US*, *government*, *official*, *Prime Minister*, *Palestinian* và *military*. Các từ này phản ánh nội dung liên quan đến chính trị, xung đột, quan hệ quốc tế và sự kiện toàn cầu. Một số từ như *said*, *quot*, *AP* và *Reuters* cũng xuất hiện với tần suất cao do đặc thù văn bản tin tức thường trích dẫn phát ngôn hoặc nguồn tin.

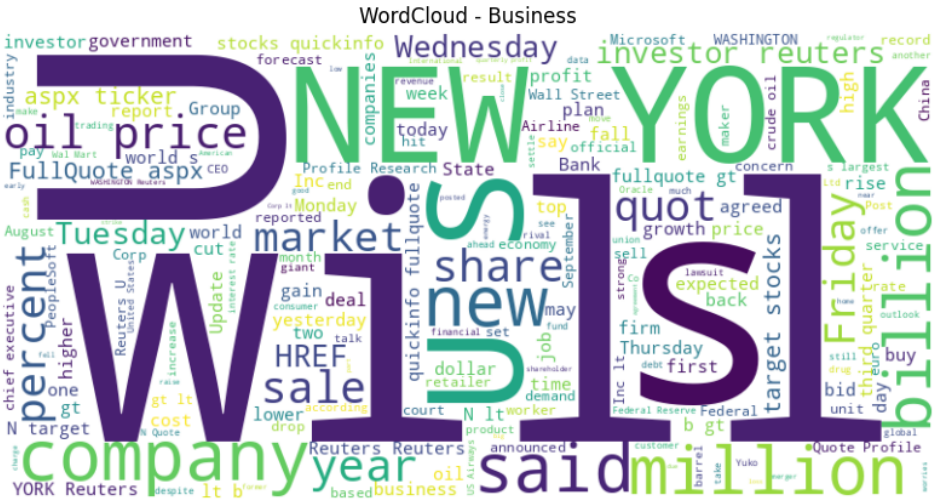

Figure 6: WordCloud của lớp Business

Đối với lớp *Business*, các từ nổi bật gồm *company*, *market*, *stock*, *sale*, *profit*, *price*, *investor* và *oil*. Đây là các từ khóa đặc trưng cho lĩnh vực kinh doanh, tài chính và thị trường. Sự xuất hiện rõ ràng của các từ chuyên ngành cho thấy lớp *Business* có khả năng được phân biệt tốt bằng các đặc trưng dựa trên tần suất từ.

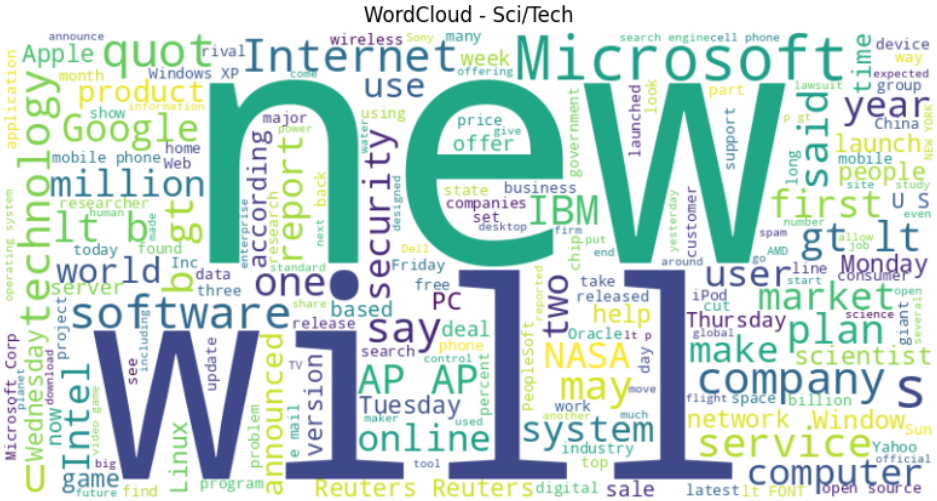
WordCloud - Sci/Tech
new
will
Microsoft
Internet
software
technology
system
computer
company
Google
Intel
Linux
Reuters
AP
NASA
IBM
million
world
online
service
market
plan
year
first
security
report
Tuesday
Monday
Thursday
Wednesday
Apple
quot
product
use
say
user
make
may
two
one
PC
game
network
Windows
scientist
launch
people
offer
price
deal
help
sale
digital
Oracle
iPod
Yahoo
Sun
Microsoft Corp
application
operating system
announced
version
according
research
enterprise
software
system
computer
company
service
network
Window
Linux
Intel
Google
Apple
Internet
Microsoft
security
report
announced
according
software
technology
million
world
online
service
market
plan
year
first
people
launch
company
computer
system
software
Microsoft
Internet
Google
Apple
Intel
Linux
Reuters
AP
NASA
IBM
Tuesday
Monday
Thursday
Wednesday
quot
product
use
say
user
make
may
two
one
PC
game
network
Windows
scientist

Kết quả cho thấy các từ xuất hiện nhiều nhất chủ yếu là các từ chức năng trong tiếng Anh như *the*, *to*, *of*, *in*, *and*, *on*, *for*. Đây là các stop words có tần suất cao nhưng thường không mang nhiều ý nghĩa phân biệt chủ đề. Ngoài ra, một số từ đặc trưng của dữ liệu tin tức như *said*, *reuters*, *new* cũng xuất hiện thường xuyên.

Kết quả này cho thấy bước loại bỏ stop words trong pipeline truyền thống là cần thiết nhằm giảm nhiễu và giúp mô hình tập trung vào các từ khóa có giá trị phân loại cao hơn. Đối với các phương pháp như Bag of Words và TF-IDF, việc xử lý stop words có ảnh hưởng trực tiếp đến chất lượng vector đặc trưng. Trong khi đó, đối với pipeline học sâu sử dụng DistilBERT, mô hình có khả năng khai thác ngữ cảnh tốt hơn nên không nhất thiết phải loại bỏ toàn bộ stop words như trong pipeline truyền thống.

e. Nhận xét tổng hợp

Từ các kết quả phân tích trên, có thể rút ra một số nhận xét chính. Thứ nhất, bộ dữ liệu có phân phối nhãn cân bằng giữa bốn lớp, giúp quá trình huấn luyện và đánh giá mô hình ổn định hơn. Thứ hai, độ dài văn bản tương đối ngắn và tập trung chủ yếu quanh khoảng 30 đến 45 từ, phù hợp với các phương pháp trích xuất đặc trưng truyền thống như Bag of Words và TF-IDF. Thứ ba, mỗi lớp có một nhóm từ khóa đặc trưng riêng, ví dụ lớp *Sports* nổi bật với các từ liên quan đến trận đấu và đội tuyển, lớp *Business* nổi bật với các từ liên quan đến thị trường và doanh nghiệp, trong khi lớp *Sci/Tech* có nhiều từ liên quan đến công nghệ và phần mềm.

Tuy nhiên, dữ liệu cũng tồn tại một số yếu tố cần lưu ý. Một số từ không mang nhiều ý nghĩa phân loại như stop words, tên hãng tin và ký hiệu trích dẫn xuất hiện với tần suất cao. Ngoài ra, có sự giao thoa từ vựng giữa một số lớp, đặc biệt là giữa *Business* và *Sci/Tech*, do các bản tin công nghệ thường có nội dung liên quan đến doanh nghiệp, sản phẩm và thị trường. Những đặc điểm này là cơ sở để nhóm lựa chọn các bước tiền xử lý phù hợp, đồng thời đánh giá mô hình bằng nhiều chỉ số khác nhau thay vì chỉ dựa vào accuracy.

3. Pipeline học máy truyền thống

a. Tiền xử lý dữ liệu

Trong pipeline học máy truyền thống, dữ liệu văn bản cần được tiền xử lý trước khi đưa vào các phương pháp trích xuất đặc trưng như Bag of Words và TF-IDF. Mục tiêu của bước này là chuẩn hóa dữ liệu đầu vào, loại bỏ các thành phần gây nhiễu và đưa văn bản về dạng phù hợp để biểu diễn thành vector số.

Ban đầu, mỗi mẫu dữ liệu trong bộ AG News gồm hai trường chính là *title* và *description*. Nhóm tiến hành ghép hai trường này thành một cột văn bản duy nhất có tên là `text`. Việc ghép tiêu đề và mô tả giúp mô hình tận dụng được nhiều thông tin hơn từ mỗi bản tin, thay vì chỉ dựa vào một phần nội dung riêng lẻ.

Sau đó, nhóm xây dựng module tiền xử lý văn bản tTextPreprocessor trong file *modules/preprocessing.py*. Quá trình tiền xử lý được áp dụng cho cả tập huấn luyện và tập kiểm tra, tạo ra cột mới có tên *clean*. Các bước xử lý chính bao gồm:

- **Chuyển chữ thường**: toàn bộ văn bản được chuyển về chữ thường nhằm tránh việc cùng một từ bị xem là các đặc trưng khác nhau do khác biệt chữ hoa và chữ thường.
- **Loại bỏ ký tự không phải chữ cái**: các chữ số, dấu câu và ký tự đặc biệt được loại bỏ bằng biểu thức chính quy. Bước này giúp giảm nhiễu trong dữ liệu văn bản.
- **Chuẩn hóa khoảng trắng**: các khoảng trắng liên tiếp được thay bằng một khoảng trắng duy nhất, đồng thời loại bỏ khoảng trắng thừa ở đầu và cuối chuỗi.
- **Tokenization**: văn bản được tách thành các token dựa trên khoảng trắng. Đây là bước chuẩn bị cần thiết trước khi loại bỏ từ dừng và xây dựng vector đặc trưng.
- **Loại bỏ token quá ngắn**: các token có độ dài nhỏ hơn 2 ký tự được loại bỏ vì thường không mang nhiều ý nghĩa phân loại.
- **Loại bỏ stop words**: các từ dừng phổ biến trong tiếng Anh như *the*, *is*, *to*, *of*, *and* được loại bỏ bằng danh sách stop words của thư viện NLTK. Đây là bước quan trọng đối với pipeline truyền thống vì các từ này có tần suất cao nhưng thường không giúp phân biệt chủ đề văn bản.

Trong phần hiện thực, nhóm có hỗ trợ tùy chọn stemming bằng thuật toán *Porter Stemmer*. Tuy nhiên, ở cấu hình thực nghiệm chính, nhóm đặt `use_stemming = False` và `remove_stopwords = True`. Việc không sử dụng stemming giúp giữ nguyên dạng từ gốc, tránh làm mất một phần ý nghĩa ngữ nghĩa của từ trong ngữ cảnh tin tức. Trong khi đó, việc loại bỏ stop words giúp giảm số lượng đặc trưng không cần thiết và cải thiện chất lượng biểu diễn của Bag of Words và TF-IDF.

Hình 9 minh họa 10 dòng dữ liệu đầu tiên trước và sau khi tiền xử lý. Có thể thấy văn bản sau xử lý đã được chuyển về chữ thường, loại bỏ dấu câu, chữ số, ký tự đặc biệt và các stop words phổ biến. Ví dụ, cụm văn bản gốc như *"Wall St. Bears Claw Back Into the Black"* được chuyển thành dạng rút gọn hơn như *"wall st bears claw back black"*. Điều này giúp giữ lại các từ khóa quan trọng, đồng thời giảm nhiễu cho các bước trích xuất đặc trưng phía sau.

	Original Text	Cleaned Text
0	Wall St. Bears Claw Back Into the Black (Reute...	wall st bears claw back black reuters reuters ...
1	Carlyle Looks Toward Commercial Aerospace (Reu...	carlyle looks toward commercial aerospace reut...
2	Oil and Economy Cloud Stocks' Outlook (Reuters...	oil economy cloud stocks outlook reuters reute...
3	Iraq Halts Oil Exports from Main Southern Pipe...	iraq halts oil exports main southern pipeline ...
4	Oil prices soar to all-time record, posing new...	oil prices soar time record posing new menace ...
5	Stocks End Up, But Near Year Lows (Reuters) Re...	stocks end near year lows reuters reuters stoc...
6	Money Funds Fell in Latest Week (AP) AP - Asse...	money funds fell latest week ap ap assets nati...
7	Fed minutes show dissent over inflation (USATO...	fed minutes show dissent inflation usatoday co...
8	Safety Net (Forbes.com) Forbes.com - After ear...	safety net forbes com forbes com earning ph so...
9	Wall St. Bears Claw Back Into the Black NEW Y...	wall st bears claw back black new york reuters...

Figure 9: So sánh văn bản trước và sau bước tiền xử lý

Sau bước tiền xử lý, cột `clean` được sử dụng làm đầu vào cho các phương pháp trích xuất đặc trưng truyền thống. Cách xử lý này đặc biệt phù hợp với Bag of Words và TF-IDF vì hai phương pháp này phụ thuộc trực tiếp vào tần suất xuất hiện của từ trong văn bản. Khi các thành phần ít giá trị như stop words, ký tự đặc biệt và khoảng trắng thừa được loại bỏ, vector đặc trưng thu được trở nên gọn hơn và tập trung hơn vào các từ khóa có khả năng phân biệt chủ đề.

b. Trích xuất đặc trưng

Sau bước tiền xử lý, văn bản trong cột `clean` vẫn ở dạng chuỗi ký tự nên chưa thể đưa trực tiếp vào các mô hình học máy truyền thống. Do đó, nhóm thực hiện bước trích xuất đặc trưng nhằm chuyển đổi văn bản thành các vector số học. Trong pipeline truyền thống, nhóm sử dụng hai phương pháp biểu diễn văn bản phổ biến là **Bag of Words** và **TF-IDF**.

Phần trích xuất đặc trưng được hiện thực trong module `modules/feature_extraction.py`, thông qua hàm `extract_traditional`. Hàm này nhận đầu vào là tập văn bản đã được tiền xử lý của tập huấn luyện và tập kiểm tra. Tùy theo tham số `method`, hàm sẽ sử dụng `CountVectorizer` cho Bag of Words hoặc `TfidfVectorizer` cho TF-IDF. Trong cả hai trường hợp, nhóm sử dụng tham số `max_features = 5000` và `ngram_range = (1, 2)`.

Việc sử dụng `max_features = 5000` giúp giới hạn số lượng đặc trưng đầu vào, tránh làm ma trận đặc trưng quá lớn và giảm chi phí tính toán khi huấn luyện mô hình. Trong khi đó, `ngram_range = (1, 2)` cho phép mô hình khai thác cả unigram và bigram. Điều này giúp biểu diễn văn bản không chỉ dựa trên từng từ riêng lẻ mà còn có thể giữ lại một phần thông tin ngữ cảnh ngắn, ví dụ như các cụm từ có ý nghĩa trong tin tức.

Với phương pháp **Bag of Words**, mỗi văn bản được biểu diễn bằng vector tần suất xuất hiện của các từ hoặc cụm từ trong bộ từ vựng. Phương pháp này đơn giản, dễ hiểu và phù hợp để xây dựng baseline cho bài toán phân loại văn bản. Tuy nhiên, Bag of Words chỉ xét số lần xuất hiện của từ mà chưa phản ánh mức độ quan trọng tương đối của từ trong toàn bộ tập dữ liệu.

Với phương pháp **TF-IDF**, mỗi từ được gán trọng số dựa trên tần suất xuất hiện trong văn bản và mức độ hiếm của từ trong toàn bộ tập dữ liệu. Các từ xuất hiện thường xuyên trong một

văn bản nhưng ít xuất hiện ở các văn bản khác sẽ có trọng số cao hơn. Vì vậy, TF-IDF thường giúp giảm ảnh hưởng của các từ phổ biến và làm nổi bật các từ có giá trị phân biệt chủ đề.

Một điểm quan trọng trong quá trình hiện thực là vectorizer chỉ được `fit` trên tập huấn luyện, sau đó dùng cùng vectorizer đó để `transform` tập kiểm tra. Cách làm này giúp tránh hiện tượng rò rỉ dữ liệu từ tập kiểm tra vào quá trình xây dựng bộ từ vựng và đảm bảo kết quả đánh giá khách quan hơn.

Sau khi trích xuất, các đặc trưng được lưu dưới định dạng `.npy` để tái sử dụng trong các lần chạy sau. Cụ thể, nhóm lưu các ma trận đặc trưng và nhãn vào thư mục `features/`. Việc lưu sẵn đặc trưng giúp giảm đáng kể thời gian chạy notebook, đặc biệt trong môi trường Google Colab, vì không cần thực hiện lại toàn bộ quá trình vector hóa văn bản ở mỗi lần chạy.

Table 3: Các file đặc trưng truyền thống được sử dụng trong pipeline

Tên file	**Ý nghĩa**
`X_train_bow.npy`	Ma trận đặc trưng Bag of Words của tập huấn luyện.
`X_test_bow.npy`	Ma trận đặc trưng Bag of Words của tập kiểm tra.
`X_train_tfidf.npy`	Ma trận đặc trưng TF-IDF của tập huấn luyện.
`X_test_tfidf.npy`	Ma trận đặc trưng TF-IDF của tập kiểm tra.
`y_train.npy`	Nhãn tương ứng của tập huấn luyện.
`y_test.npy`	Nhãn tương ứng của tập kiểm tra.

Trong notebook, nhóm thiết lập cơ chế sử dụng lại các đặc trưng đã trích xuất trước đó bằng biến cấu hình `USE_PRECOMPUTED_FEATURES = True`. Khi các file đặc trưng chưa tồn tại trong môi trường Colab, notebook sẽ tự động tải file nén chứa đặc trưng từ Hugging Face, sau đó giải nén vào thư mục `features/`. Link tải đặc trưng truyền thống được sử dụng trong notebook là: Nhấn vào đây

Cách tổ chức này phù hợp với yêu cầu của bài tập lớn vì dữ liệu đặc trưng vẫn được lưu dưới định dạng `.npy`, đồng thời notebook có thể chạy lại từ đầu mà không cần phụ thuộc vào Google Drive hoặc dịch vụ lưu trữ cá nhân. File `.zip` chỉ đóng vai trò là định dạng nén để thuận tiện cho việc tải xuống và giải nén trong Colab.

Lý do cho việc này là các file trích xuất đặc trưng quá nặng, và sẽ tốn thời gian rất nhiều khi người khác muốn runtime -> run all, vậy nên nhóm đã thực hiện trích xuất đặc trưng và đăng tải Public lên Hugging Face nhằm tối ưu thời gian.

Sau khi tải và kiểm tra đầy đủ các file `.npy`, nhóm tiếp tục chuyển đổi các ma trận đặc trưng dạng dense sang dạng sparse CSR và lưu vào thư mục `features_ sparse_cache/`. Quá trình chuyển đổi được thực hiện theo từng phần nhỏ bằng `chunk_size = 5000` nhằm tránh sử dụng quá nhiều RAM. Các file sparse sau đó được nạp bằng `load_npz` và sử dụng trực tiếp cho quá trình huấn luyện các mô hình truyền thống.

Việc chuyển đổi sang sparse matrix là cần thiết vì đặc trưng BoW và TF-IDF thường có rất nhiều phần tử bằng 0. Nếu lưu và xử lý ở dạng dense, bộ nhớ sử dụng sẽ lớn hơn đáng kể. Ngược lại, định dạng sparse chỉ lưu các phần tử khác 0, giúp giảm chi phí bộ nhớ và tăng hiệu quả khi huấn luyện các mô hình như Naive Bayes, Logistic Regression và Linear SVM.

Tóm lại, bước trích xuất đặc trưng trong pipeline truyền thống gồm ba giai đoạn chính: chuyển văn bản đã tiền xử lý thành vector bằng Bag of Words và TF-IDF, lưu các đặc trưng dưới định dạng `.npy` để tái sử dụng, sau đó chuyển sang sparse CSR để tối ưu quá trình huấn luyện. Cách hiện thực này giúp notebook chạy ổn định hơn trên Colab, đồng thời vẫn đảm bảo đúng yêu cầu về lưu trữ và sử dụng file đặc trưng của bài tập lớn.

c. Huấn luyện và đánh giá mô hình

Sau khi hoàn thành bước trích xuất đặc trưng, nhóm tiến hành huấn luyện các mô hình học máy truyền thống trên hai dạng đặc trưng: **Bag of Words** và **TF-IDF**. Mục tiêu của bước này là đánh giá khả năng phân loại văn bản của các mô hình truyền thống khi sử dụng các biểu diễn văn bản khác nhau.

Ba mô hình được sử dụng trong pipeline truyền thống bao gồm:

- **Naive Bayes**: là mô hình xác suất đơn giản, thường được sử dụng làm baseline cho các bài toán phân loại văn bản. Mô hình có tốc độ huấn luyện rất nhanh và phù hợp với dữ liệu có số chiều lớn như BoW và TF-IDF.
- **Logistic Regression**: là mô hình tuyến tính có khả năng học ranh giới phân loại giữa các lớp. Trong bài toán văn bản, Logistic Regression thường cho kết quả ổn định khi kết hợp với các đặc trưng thưa có số chiều cao.
- **Linear Support Vector Machine**: là mô hình phân loại tuyến tính dựa trên nguyên lý cực đại hóa biên phân tách giữa các lớp. Linear SVM thường hoạt động tốt trên dữ liệu văn bản vì dữ liệu sau khi vector hóa thường có số chiều lớn và có tính phân tách tuyến tính tương đối cao.

Các mô hình được huấn luyện trên tập huấn luyện gồm 120000 mẫu và được đánh giá trên tập kiểm tra gồm 7600 mẫu. Vì tập kiểm tra có phân phối nhãn cân bằng, mỗi lớp gồm 1900 mẫu, nhóm sử dụng nhiều chỉ số đánh giá khác nhau gồm **Accuracy**, **Precision**, **Recall**, **F1-score**, **Macro F1** và **Weighted F1**. Trong đó, *Accuracy* phản ánh tỷ lệ dự đoán đúng tổng thể, còn *Macro F1* giúp đánh giá hiệu quả trung bình giữa các lớp mà không bị ảnh hưởng bởi số lượng mẫu từng lớp.

Table 4: Tổng hợp kết quả huấn luyện và đánh giá các mô hình truyền thống

Đặc trưng	**Mô hình**	**Thời gian huấn luyện (s)**	**Accuracy**	**Macro F1**	**Weighted F1**
BoW	Naive Bayes	0.06	0.8892	0.8888	0.8888
BoW	Logistic Regression	9.16	0.8974	0.8972	0.8972
BoW	**Linear SVM**	1.48	**0.9087**	**0.9085**	**0.9085**
TF-IDF	Naive Bayes	0.03	0.8900	0.8897	0.8897
TF-IDF	Logistic Regression	8.86	0.9054	0.9052	0.9052
TF-IDF	Linear SVM	0.88	0.9024	0.9020	0.9020

Từ Bảng 4, có thể thấy tất cả các mô hình truyền thống đều đạt kết quả tương đối cao, với Accuracy nằm trong khoảng từ 88.92% đến 90.87%. Trong đó, mô hình **Linear SVM kết hợp với Bag of Words** đạt kết quả tốt nhất với Accuracy là **90.87%**, Macro F1 là **90.85%** và Weighted F1 là **90.85%**. Điều này cho thấy biểu diễn BoW tuy đơn giản nhưng vẫn có hiệu quả cao khi kết hợp với mô hình tuyến tính phù hợp như Linear SVM.

Để biểu diễn trực quan hơn sự khác biệt giữa các cấu hình, kết quả Accuracy và Macro F1 có thể được trình bày dưới dạng ma trận so sánh như sau:

Mô hình	**BoW**	**TF-IDF**
Naive Bayes	0.8892	0.8900
Logistic Regression	0.8974	0.9054
Linear SVM	**0.9087**	0.9024

Ma trận so sánh Accuracy giữa các mô hình và phương pháp trích xuất đặc trưng

Mô hình	**BoW**	**TF-IDF**
Naive Bayes	0.8888	0.8897
Logistic Regression	0.8972	0.9052
Linear SVM	**0.9085**	0.9020

Ma trận so sánh Macro F1 giữa các mô hình và phương pháp trích xuất đặc trưng

Kết quả trên cho thấy ảnh hưởng của phương pháp trích xuất đặc trưng phụ thuộc vào từng mô hình. Với **Naive Bayes**, sự khác biệt giữa BoW và TF-IDF không đáng kể. Với **Logistic Regression**, TF-IDF cho kết quả cao hơn BoW, thể hiện qua Accuracy tăng từ 0.8974 lên 0.9054. Ngược lại, với **Linear SVM**, BoW cho kết quả tốt hơn TF-IDF, đạt Accuracy cao nhất trong toàn bộ pipeline truyền thống.

Bảng 5 trình bày chi tiết kết quả theo từng lớp của mô hình tốt nhất trong pipeline truyền thống, tức **Linear SVM kết hợp với Bag of Words**.

Table 5: Classification report của mô hình Linear SVM + BoW

Lớp	**Precision**	**Recall**	**F1-score**	**Support**
World	0.93	0.89	0.91	1900
Sports	0.95	0.98	0.96	1900
Business	0.88	0.87	0.88	1900
Sci/Tech	0.87	0.89	0.88	1900
Accuracy		**0.9087**		7600
Macro avg	0.91	0.91	0.91	7600
Weighted avg	0.91	0.91	0.91	7600

Dựa trên Bảng 5, lớp *Sports* đạt kết quả cao nhất với F1-score là 0.96. Điều này phù hợp với kết quả EDA, vì các văn bản thuộc lớp thể thao thường có nhiều từ khóa đặc trưng như *game*, *team*, *win*, *season* và *player*. Các từ này giúp mô hình dễ dàng nhận diện chủ đề thể thao.

Trong khi đó, hai lớp *Business* và *Sci/Tech* có F1-score thấp hơn, lần lượt là 0.88 và 0.88. Nguyên nhân có thể đến từ sự giao thoa về từ vựng giữa hai nhóm chủ đề này. Ví dụ, các bản tin công nghệ thường đề cập đến công ty, thị trường, sản phẩm, lợi nhuận hoặc cổ phiếu; đây cũng là những từ thường gặp trong lớp kinh doanh. Do đó, một số mẫu thuộc lớp *Sci/Tech* có thể bị nhầm sang *Business* và ngược lại.

Ngoài kết quả tổng hợp, nhóm cũng kiểm tra một số dự đoán đầu tiên của mô hình để quan sát trực tiếp khả năng phân loại. Bảng 6 minh họa 10 dự đoán đầu tiên của mô hình **Linear SVM + BoW**.

Table 6: Minh họa 10 dự đoán đầu tiên của mô hình Linear SVM + BoW

Mẫu	**Nhãn thực tế**	**Nhãn dự đoán**	**Kết quả**
1	Business	Business	Đúng
2	Sci/Tech	Sci/Tech	Đúng
3	Sci/Tech	Sci/Tech	Đúng
4	Sci/Tech	Sports	Sai
5	Sci/Tech	Sci/Tech	Đúng
6	Sci/Tech	Sci/Tech	Đúng
7	Sci/Tech	Sci/Tech	Đúng
8	Sci/Tech	Sci/Tech	Đúng
9	Sci/Tech	Sci/Tech	Đúng
10	Sci/Tech	Business	Sai

Kết quả minh họa cho thấy mô hình dự đoán đúng phần lớn các mẫu đầu tiên, tuy nhiên vẫn xuất hiện một số lỗi phân loại. Đáng chú ý, một mẫu thuộc lớp *Sci/Tech* bị dự đoán thành *Sports* và một mẫu khác bị dự đoán thành *Business*. Điều này cho thấy mặc dù mô hình đạt hiệu quả tổng thể cao, vẫn tồn tại các trường hợp văn bản có nội dung hoặc từ khóa gây nhiễu khiến mô hình nhầm lẫn giữa các lớp.

Xét về thời gian huấn luyện, **Naive Bayes** có tốc độ nhanh nhất, chỉ mất khoảng 0.03 đến 0.06 giây. Tuy nhiên, hiệu quả phân loại của mô hình này thấp hơn so với Logistic Regression và Linear SVM. **Logistic Regression** đạt kết quả tốt nhưng có thời gian huấn luyện cao nhất, khoảng 8.86 đến 9.16 giây. Trong khi đó, **Linear SVM** đạt sự cân bằng tốt giữa hiệu năng và thời gian huấn luyện, đặc biệt với cấu hình BoW, mô hình chỉ mất 1.48 giây để huấn luyện nhưng đạt kết quả cao nhất.

Tóm lại, trong pipeline học máy truyền thống, mô hình **Linear SVM kết hợp với Bag of Words** là cấu hình tốt nhất. Kết quả này cho thấy các phương pháp truyền thống vẫn có khả năng đạt hiệu quả cao đối với bài toán phân loại văn bản khi dữ liệu được tiền xử lý phù hợp và đặc trưng được biểu diễn tốt.

d. So sánh trực quan giữa các mô hình

Để trực quan hóa sự khác biệt về hiệu năng giữa các mô hình, nhóm biểu diễn kết quả Accuracy của từng mô hình theo hai phương pháp trích xuất đặc trưng là Bag of Words và TF-IDF. Hình 10 cho thấy các mô hình tuyến tính, đặc biệt là Linear SVM và Logistic Regression, đạt hiệu quả cao hơn so với Naive Bayes trên cả hai loại đặc trưng.

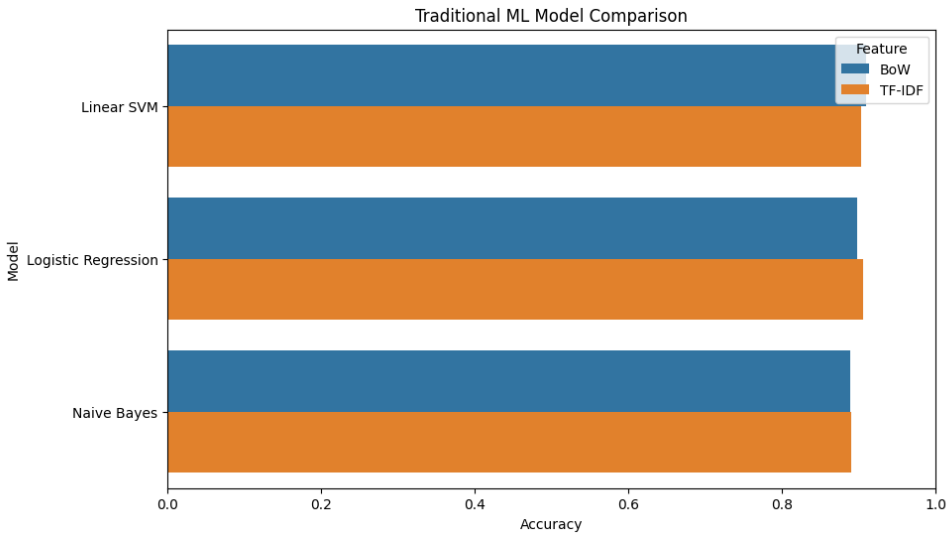

Figure 10: So sánh Accuracy giữa các mô hình học máy truyền thống

Từ biểu đồ trên, có thể thấy cấu hình **Linear SVM + BoW** đạt Accuracy cao nhất. Trong khi đó, **Logistic Regression + TF-IDF** cũng cho kết quả rất gần với mô hình tốt nhất. Điều này cho thấy cả BoW và TF-IDF đều có khả năng biểu diễn văn bản hiệu quả khi kết hợp với các mô hình tuyến tính. Tuy nhiên, hiệu quả của từng phương pháp trích xuất đặc trưng còn phụ thuộc vào mô hình phân loại được sử dụng.

Bảng 7 trình bày bảng xếp hạng đầy đủ các thí nghiệm theo Accuracy giảm dần. Ngoài Accuracy, nhóm cũng ghi nhận thêm Macro Precision, Macro Recall, Macro F1, Weighted F1 và thời gian huấn luyện để đánh giá toàn diện hơn giữa các cấu hình.

Table 7: Bảng xếp hạng kết quả các mô hình truyền thống

Hạng	Mô hình	Đặc trưng	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1	Thời gian huấn luyện (s)
1	Linear SVM	BoW	**0.9087**	**0.9087**	**0.9087**	**0.9085**	**0.9085**	1.4812
2	Logistic Regression	TF-IDF	0.9054	0.9051	0.9054	0.9052	0.9052	8.8577
3	Linear SVM	TF-IDF	0.9024	0.9019	0.9024	0.9020	0.9020	0.8824
4	Logistic Regression	BoW	0.8974	0.8971	0.8974	0.8972	0.8972	9.1650
5	Naive Bayes	TF-IDF	0.8900	0.8895	0.8900	0.8897	0.8897	0.0346
6	Naive Bayes	BoW	0.8892	0.8886	0.8892	0.8888	0.8888	0.0607

Kết quả trong Bảng 7 cho thấy **Linear SVM + BoW** là cấu hình tốt nhất trong pipeline truyền thống, đạt Accuracy là **90.87%** và Macro F1 là **90.85%**. Đây là kết quả cao nhất trong toàn bộ sáu thí nghiệm truyền thống. Mô hình này cũng có thời gian huấn luyện tương đối thấp, chỉ khoảng 1.48 giây, cho thấy sự cân bằng tốt giữa hiệu năng và chi phí tính toán.

Cấu hình đứng thứ hai là **Logistic Regression + TF-IDF**, đạt Accuracy là **90.54%** và Macro F1 là **90.52%**. Kết quả này cho thấy TF-IDF giúp Logistic Regression khai thác tốt hơn các từ có giá trị phân biệt chủ đề. Tuy nhiên, thời gian huấn luyện của Logistic Regression cao hơn đáng kể so với Linear SVM, khoảng 8.86 giây.

Hai cấu hình sử dụng **Naive Bayes** có tốc độ huấn luyện nhanh nhất, chỉ khoảng 0.03 đến 0.06 giây, nhưng hiệu quả phân loại thấp hơn so với Logistic Regression và Linear SVM. Điều này phù hợp với đặc điểm của Naive Bayes: mô hình đơn giản, huấn luyện nhanh nhưng giả định độc lập giữa các đặc trưng nên có thể chưa khai thác tốt mối quan hệ giữa các từ trong văn bản.

Nhìn chung, các kết quả trên cho thấy mô hình tuyến tính có hiệu quả tốt đối với dữ liệu văn bản sau khi được biểu diễn bằng BoW hoặc TF-IDF. Trong phạm vi pipeline truyền thống, nhóm chọn **Linear SVM + BoW** là cấu hình tốt nhất để so sánh với pipeline học sâu ở các phần tiếp theo.

4. Pipeline học sâu (Deep Learning)

a. Tiền xử lý và trích xuất đặc trưng

Bên cạnh pipeline học máy truyền thống, nhóm xây dựng thêm một pipeline học sâu nhằm khai thác biểu diễn ngữ nghĩa của văn bản thông qua mô hình ngôn ngữ đã được huấn luyện trước. Thay vì biểu diễn văn bản bằng tần suất từ như Bag of Words hoặc TF-IDF, pipeline học sâu sử dụng vector embedding được trích xuất từ mô hình **DistilBERT**. Đây là phiên bản rút gọn của BERT, có kích thước nhỏ hơn và tốc độ xử lý nhanh hơn, nhưng vẫn giữ được khả năng biểu diễn ngữ nghĩa ngữ cảnh của văn bản.

Trong pipeline học sâu, dữ liệu đầu vào vẫn là cột văn bản được tạo từ việc ghép `title` và `description`. Tuy nhiên, khác với pipeline truyền thống, nhóm không thực hiện loại bỏ stop words hoặc stemming trước khi đưa văn bản vào mô hình DistilBERT. Nguyên nhân là các mô hình Transformer như DistilBERT được huấn luyện để khai thác ngữ cảnh dựa trên toàn bộ chuỗi đầu vào, bao gồm cả các từ chức năng. Nếu loại bỏ quá nhiều từ hoặc biến đổi từ quá mạnh, thông tin ngữ cảnh của câu có thể bị suy giảm.

Về mặt xử lý, văn bản được chuẩn bị theo quy trình phù hợp với mô hình Transformer. Mỗi văn bản được mã hóa bằng tokenizer của DistilBERT, chuyển thành các chỉ số token đầu vào. Sau đó, các chuỗi token được chuẩn hóa về cùng độ dài bằng padding hoặc truncation. Các tensor đầu vào này được đưa qua mô hình DistilBERT để trích xuất vector biểu diễn ngữ nghĩa. Trong quá trình này, nhóm sử dụng vector đặc trưng ở đầu ra của mô hình làm embedding đại diện cho toàn bộ văn bản. Mỗi mẫu văn bản được biểu diễn bằng một vector có kích thước **768 chiều**.

Quy trình trích xuất đặc trưng học sâu có thể được tóm tắt như sau:

`Text` → `DistilBERT Tokenizer` → `Input IDs + Attention Mask` → `DistilBERT` → `768-dimensional Embedding` → `.npy Feature Files`

Do quá trình trích xuất embedding bằng DistilBERT tốn nhiều thời gian và phụ thuộc vào tài nguyên GPU, nhóm không thực hiện lại bước này trong mỗi lần chạy notebook chính. Thay vào đó, các đặc trưng học sâu đã được trích xuất trước và lưu lại dưới định dạng `.npy`. Trong file `pline.ipynb`, nhóm thiết lập cơ chế tự động tải các file đặc trưng học sâu từ Hugging Face nếu chúng chưa tồn tại trong môi trường Colab. Link tải file đặc trưng học sâu được sử dụng trong notebook là: Nhấn vào đây

Trong notebook, biến `DEEP_FEATURE_URL` được dùng để lưu đường dẫn tải file nén, còn thư mục `features/deep/` được dùng để lưu các file đặc trưng sau khi giải nén. Cách tổ chức này giúp notebook có thể chạy lại từ đầu trên Google Colab mà không cần mount Google Drive hoặc phụ thuộc vào bộ nhớ cá nhân.

Các file đặc trưng học sâu bắt buộc được kiểm tra trong notebook gồm:

Table 8: Các file đặc trưng học sâu được sử dụng trong pipeline

Tên file	**Ý nghĩa**
`features/deep/X_train_bert.npy`	Ma trận embedding DistilBERT của tập huấn luyện. Mỗi dòng tương ứng với một văn bản, mỗi vector có 768 chiều.
`features/deep/X_test_bert.npy`	Ma trận embedding DistilBERT của tập kiểm tra.
`features/deep/y_train_bert.npy`	Nhãn tương ứng của các mẫu trong tập huấn luyện.
`features/deep/y_test_bert.npy`	Nhãn tương ứng của các mẫu trong tập kiểm tra.

Sau khi tải và giải nén file `ft_deeplearning.zip`, notebook kiểm tra sự tồn tại của đầy đủ bốn file trên. Nếu thiếu bất kỳ file nào, chương trình sẽ báo lỗi để tránh việc huấn luyện mô hình trên dữ liệu không đầy đủ. Khi các file đã tồn tại, notebook sẽ nạp dữ liệu bằng hàm `np.load`. Cụ thể, các biến `X_train_bert` và `X_test_bert` chứa ma trận đặc trưng đầu vào, còn `y_train_bert` và `y_test_bert` chứa nhãn tương ứng.

Table 9: Cấu hình đặc trưng học sâu trong notebook

Thành phần	**Giá trị**
Mô hình trích xuất đặc trưng	DistilBERT
Loại đặc trưng	DistilBERT Embedding
Kích thước vector đầu vào	768
Số mẫu huấn luyện	120000
Số mẫu kiểm tra	7600
Định dạng lưu trữ	`.npy`
Thư mục lưu đặc trưng	`features/deep/`
Nguồn tải đặc trưng	Hugging Face

Một bước tiền xử lý quan trọng khác trong pipeline học sâu là chuẩn hóa nhãn để phù hợp với hàm mất mát của PyTorch. Trong bộ dữ liệu gốc, nhãn của AG News được mã hóa từ 1 đến 4, tương ứng với bốn lớp *World*, *Sports*, *Business* và *Sci/Tech*. Tuy nhiên, hàm `CrossEntropyLoss` trong PyTorch yêu cầu nhãn lớp ở dạng số nguyên bắt đầu từ 0. Vì vậy, trong notebook, nếu phát hiện nhãn đang nằm trong khoảng 1–4, nhóm chuyển nhãn về khoảng 0–3 bằng phép biến đổi:

$$y_{\text{new}} = y_{\text{original}} - 1$$

Sau khi chuẩn hóa nhãn, các ma trận đặc trưng và nhãn được chuyển thành tensor PyTorch. Tập huấn luyện và tập kiểm tra sau đó được đóng gói bằng `TensorDataset` và đưa vào `DataLoader`. Đối với tập huấn luyện, nhóm sử dụng `shuffle=True` để xáo trộn dữ liệu giữa các epoch, giúp quá trình học ổn định hơn. Đối với tập kiểm tra, nhóm đặt `shuffle=False` để đảm bảo thứ tự dữ liệu không bị thay đổi trong quá trình đánh giá.

Table 10: Thiết lập dữ liệu đầu vào cho mô hình học sâu

Tham số	**Giá trị**
Batch size huấn luyện	128
Batch size kiểm tra	256
Kiểu dữ liệu đặc trưng	`torch.float32`
Kiểu dữ liệu nhãn	`torch.long`
Shuffle tập huấn luyện	Có
Shuffle tập kiểm tra	Không
Random state	42

Tóm lại, phần tiền xử lý và trích xuất đặc trưng của pipeline học sâu được tổ chức theo hướng tối ưu cho môi trường Google Colab. Nhóm sử dụng DistilBERT để tạo embedding ngữ nghĩa 768 chiều cho mỗi văn bản, lưu các đặc trưng này thành file `.npy`, sau đó tải lại từ Hugging Face khi chạy notebook. Cách làm này giúp giảm thời gian xử lý, tránh phụ thuộc vào GPU

trong mỗi lần chạy lại, đồng thời vẫn đảm bảo pipeline học sâu có thể được đánh giá và so sánh trực tiếp với pipeline học máy truyền thống.

b. Huấn luyện và đánh giá mô hình

Sau khi trích xuất đặc trưng bằng DistilBERT, mỗi văn bản trong bộ dữ liệu được biểu diễn bởi một vector embedding có kích thước 768 chiều. Các vector này được sử dụng làm đầu vào cho mô hình **MLP Neural Network** nhằm thực hiện bài toán phân loại văn bản đa lớp với bốn nhãn: *World*, *Sports*, *Business* và *Sci/Tech*.

Khác với pipeline truyền thống, trong pipeline học sâu, nhóm không huấn luyện trực tiếp toàn bộ mô hình Transformer từ đầu. Thay vào đó, DistilBERT được sử dụng như một bộ trích xuất đặc trưng ngữ nghĩa, sau đó mô hình MLP được huấn luyện trên các embedding đã trích xuất. Cách tiếp cận này giúp giảm đáng kể chi phí tính toán so với fine-tuning toàn bộ DistilBERT, đồng thời vẫn tận dụng được khả năng biểu diễn ngữ cảnh của mô hình ngôn ngữ đã được huấn luyện trước.

Mô hình MLP được xây dựng như một bộ phân loại nhận đầu vào là vector 768 chiều và sinh đầu ra tương ứng với 4 lớp phân loại. Trong quá trình huấn luyện, dữ liệu được chia thành các mini-batch với `batch size = 128`. Mô hình được huấn luyện trong 8 epoch với `learning rate = 0.001`. Tập kiểm tra gồm 7600 mẫu được dùng để đánh giá hiệu quả cuối cùng của mô hình.

Table 11: Cấu hình huấn luyện mô hình học sâu

Thành phần	**Giá trị**
Mô hình phân loại	MLP Neural Network
Đặc trưng đầu vào	DistilBERT Embedding
Kích thước đầu vào	768
Số lớp đầu ra	4
Số mẫu huấn luyện	120000
Số mẫu kiểm tra	7600
Số epoch	8
Batch size	128
Learning rate	0.001
Thời gian huấn luyện	84.63 giây

Trong quá trình huấn luyện, nhóm theo dõi hai đại lượng chính là *training loss* và *training accuracy*. Hình 11 cho thấy giá trị loss giảm đều qua từng epoch, từ khoảng 0.31 ở epoch đầu tiên xuống khoảng 0.22 ở epoch cuối cùng.

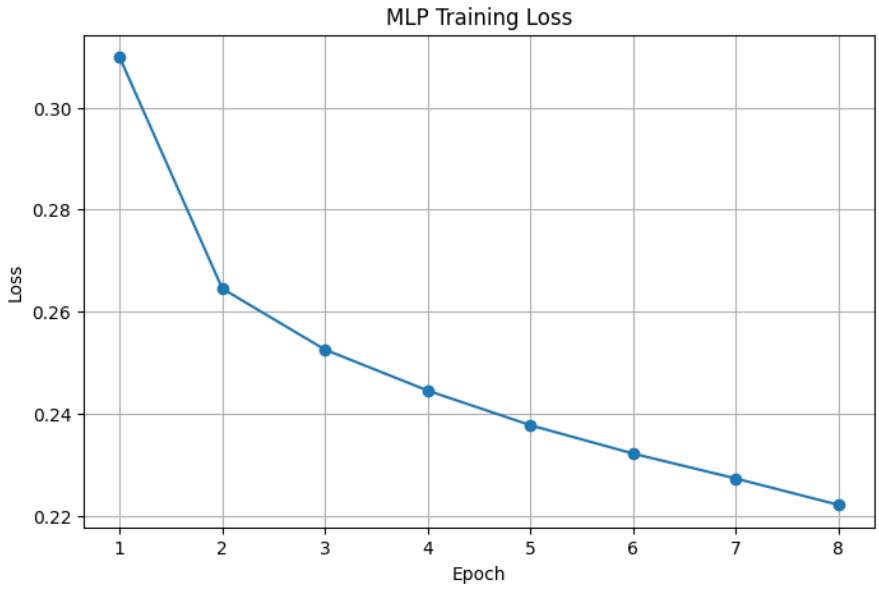

Figure 11: Biến thiên training loss của mô hình MLP qua các epoch

Xu hướng giảm đều của loss cho thấy mô hình học được các đặc trưng phân biệt giữa các lớp từ embedding DistilBERT. Đặc biệt, loss giảm mạnh từ epoch 1 sang epoch 2, sau đó tiếp tục giảm chậm hơn ở các epoch sau. Điều này cho thấy mô hình hội tụ tương đối ổn định: giai đoạn đầu mô hình học nhanh các mẫu phân biệt rõ ràng, còn các epoch sau chủ yếu tinh chỉnh ranh giới quyết định giữa các lớp khó phân biệt hơn.

Hình 12 thể hiện training accuracy của mô hình qua 8 epoch. Accuracy tăng từ khoảng 0.891 ở epoch đầu lên khoảng 0.921 ở epoch cuối.

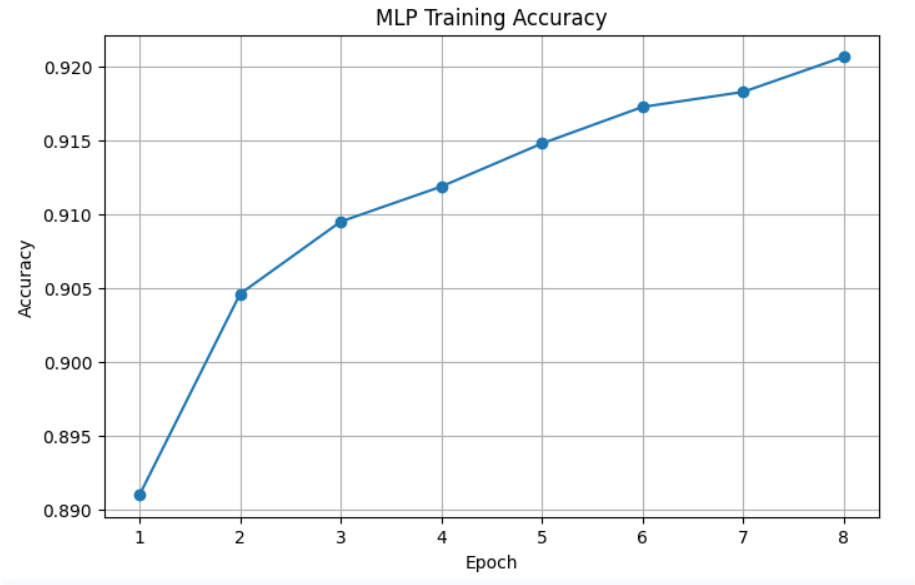

Figure 12: Biến thiên training accuracy của mô hình MLP qua các epoch

Training accuracy tăng đều qua các epoch cho thấy mô hình cải thiện dần khả năng phân loại trên tập huấn luyện. Tốc độ tăng accuracy rõ nhất ở các epoch đầu, sau đó tăng chậm hơn từ epoch 5 đến epoch 8. Điều này phù hợp với xu hướng loss giảm dần và cho thấy mô hình đã tiến gần đến trạng thái hội tụ. Không có dấu hiệu dao động bất thường trong quá trình huấn luyện, do đó quá trình tối ưu có thể được xem là ổn định.

Kết quả đánh giá cuối cùng của pipeline học sâu trên tập kiểm tra được trình bày trong Bảng 12.

Table 12: Kết quả tổng hợp của pipeline học sâu

Mô hình	Đặc trưng	Accuracy	Macro Precision	Macro Recall	Macro F1	Weighted F1
MLP Neural Network	DistilBERT Embedding	**0.9142**	**0.9153**	**0.9142**	**0.9142**	**0.9142**

Mô hình đạt **Accuracy = 0.9142**, tương đương khoảng **91.42%**. Đồng thời, **Macro F1** và **Weighted F1** đều đạt khoảng **0.9142**. Việc Macro F1 và Weighted F1 gần như bằng nhau cho thấy kết quả đánh giá không bị ảnh hưởng bởi mất cân bằng lớp. Điều này phù hợp với đặc điểm của bộ dữ liệu AG News, trong đó mỗi lớp trong tập kiểm tra đều có 1900 mẫu.

Bảng 13 trình bày chi tiết kết quả theo từng lớp.

Table 13: Classification report của mô hình MLP sử dụng DistilBERT Embedding

Lớp	**Precision**	**Recall**	**F1-score**	**Support**
World	0.94	0.90	0.92	1900
Sports	0.96	0.99	0.98	1900
Business	0.85	0.91	0.87	1900
Sci/Tech	0.91	0.86	0.89	1900
Accuracy		**0.9142**		7600
Macro avg	0.92	0.91	0.91	7600
Weighted avg	0.92	0.91	0.91	7600

Từ Bảng 13, có thể thấy lớp *Sports* đạt kết quả tốt nhất với **precision = 0.96**, **recall = 0.99** và **F1-score = 0.98**. Đây là lớp có hiệu quả phân loại cao nhất trong toàn bộ bốn lớp. Kết quả này phù hợp với phân tích EDA trước đó, vì các văn bản thể thao thường chứa nhiều từ khóa đặc trưng như *game*, *team*, *season*, *win*, *player*, giúp mô hình dễ nhận diện.

Lớp *World* cũng đạt kết quả tốt với **F1-score = 0.92**. Precision của lớp này đạt 0.94, cao hơn recall 0.90, cho thấy khi mô hình dự đoán một văn bản thuộc lớp *World* thì khả năng đúng khá cao. Tuy nhiên, vẫn có một phần mẫu thuộc lớp *World* bị dự đoán sang các lớp khác, khiến recall thấp hơn precision.

Đối với lớp *Business*, mô hình đạt **precision = 0.85**, **recall = 0.91** và **F1-score = 0.87**. Recall cao hơn precision cho thấy mô hình nhận diện được phần lớn các mẫu thuộc lớp *Business*, nhưng đồng thời cũng có một số mẫu từ lớp khác bị dự đoán nhầm thành *Business*. Điều này có thể do các tin tức thuộc nhóm công nghệ hoặc thế giới đôi khi cũng chứa các từ liên quan đến thị trường, công ty, cổ phiếu hoặc kinh tế.

Lớp *Sci/Tech* đạt **precision = 0.91**, **recall = 0.86** và **F1-score = 0.89**. Precision tương đối cao cho thấy các mẫu được dự đoán là *Sci/Tech* thường khá chính xác. Tuy nhiên, recall thấp hơn cho thấy vẫn còn một số văn bản thuộc lớp *Sci/Tech* bị mô hình phân loại sang lớp khác, đặc biệt có thể là *Business*. Đây là hiện tượng hợp lý vì tin tức công nghệ thường liên quan đến doanh nghiệp, sản phẩm, thị trường và các công ty công nghệ lớn.

Có thể tóm tắt kết quả đánh giá theo từng lớp bằng ma trận chỉ số sau:

Lớp	**Precision**	**Recall**	**F1-score**
World	0.94	0.90	0.92
Sports	0.96	0.99	0.98
Business	0.85	0.91	0.87
Sci/Tech	0.91	0.86	0.89

Nhìn chung, pipeline học sâu đạt hiệu quả cao và ổn định trên cả bốn lớp. Việc sử dụng DistilBERT Embedding giúp mô hình MLP khai thác tốt hơn thông tin ngữ nghĩa của văn bản so với các biểu diễn dựa trên tần suất từ đơn thuần. Đặc biệt, embedding ngữ cảnh có thể giúp mô hình hiểu tốt hơn các từ hoặc cụm từ có ý nghĩa khác nhau tùy theo ngữ cảnh sử dụng.

Tuy nhiên, pipeline học sâu cũng có chi phí tính toán cao hơn. Thời gian huấn luyện MLP trên các embedding DistilBERT là khoảng **84.63 giây**, cao hơn đáng kể so với các mô hình truyền thống. Ngoài ra, quá trình trích xuất embedding bằng DistilBERT ban đầu cũng đòi hỏi nhiều tài nguyên hơn, đặc biệt nếu thực hiện trực tiếp trên toàn bộ tập dữ liệu trong Google Colab. Vì vậy, nhóm đã lưu trước các embedding dưới định dạng `.npy` và tải lại khi cần, nhằm giúp notebook chạy ổn định và tiết kiệm thời gian hơn.

Tóm lại, mô hình **MLP Neural Network** sử dụng **DistilBERT Embedding** đạt kết quả tốt với Accuracy, Macro F1 và Weighted F1 đều khoảng **91.42%**. Đây là kết quả tốt nhất trong

pipeline học sâu và sẽ được sử dụng để so sánh trực tiếp với pipeline học máy truyền thống ở phần tiếp theo.

5. So sánh giữa hai pipeline

Sau khi hoàn thành hai hướng tiếp cận, nhóm tiến hành so sánh kết quả giữa pipeline học máy truyền thống và pipeline học sâu. Pipeline truyền thống sử dụng các đặc trưng dựa trên tần suất từ như **Bag of Words** và **TF-IDF**, kết hợp với các mô hình phân loại **Naive Bayes**, **Logistic Regression** và **Linear SVM**. Trong khi đó, pipeline học sâu sử dụng **DistilBERT Embedding** để biểu diễn ngữ nghĩa văn bản, sau đó huấn luyện mô hình **MLP Neural Network** để phân loại.

Mục tiêu của phần so sánh này là đánh giá sự khác biệt giữa hai pipeline trên các tiêu chí: độ chính xác, Macro F1, Weighted F1, thời gian huấn luyện và khả năng biểu diễn đặc trưng văn bản.

So sánh kết quả tổng hợp

Bảng 14 trình bày kết quả tổng hợp của toàn bộ các mô hình trong cả hai pipeline, được sắp xếp theo Accuracy giảm dần.

Table 14: So sánh tổng hợp giữa pipeline truyền thống và pipeline học sâu

Hạng	Mô hình	Đặc trưng	Accuracy	Macro Precision	Macro Recall	Macro F1	Training Time (s)
1	MLP Neural Network	DistilBERT Embedding	**0.9142**	**0.9153**	**0.9142**	**0.9142**	84.6330
2	Linear SVM	BoW	0.9087	0.9087	0.9087	0.9085	1.4812
3	Logistic Regression	TF-IDF	0.9054	0.9051	0.9054	0.9052	8.8577
4	Linear SVM	TF-IDF	0.9024	0.9019	0.9024	0.9020	0.8824
5	Logistic Regression	BoW	0.8974	0.8971	0.8974	0.8972	9.1650
6	Naive Bayes	TF-IDF	0.8900	0.8895	0.8900	0.8897	0.0346
7	Naive Bayes	BoW	0.8892	0.8886	0.8892	0.8888	0.0607

Từ Bảng 14, mô hình có kết quả cao nhất là **MLP Neural Network sử dụng DistilBERT Embedding**, đạt Accuracy là **0.9142** và Macro F1 là **0.9142**. Đây là kết quả tốt nhất trong toàn bộ các thí nghiệm. Mô hình truyền thống tốt nhất là **Linear SVM kết hợp với Bag of Words**, đạt Accuracy là **0.9087** và Macro F1 là **0.9085**.

Như vậy, pipeline học sâu cải thiện Accuracy khoảng:

$$0.9142 - 0.9087 = 0.0055$$

tương đương khoảng **0.55 điểm phần trăm** so với pipeline truyền thống tốt nhất. Đối với Macro F1, pipeline học sâu cải thiện khoảng:

$$0.9142 - 0.9085 = 0.0057$$

tương đương khoảng **0.57 điểm phần trăm**. Mức cải thiện này không quá lớn, nhưng cho thấy đặc trưng ngữ nghĩa từ DistilBERT vẫn giúp mô hình đạt hiệu quả tốt hơn so với đặc trưng tần suất từ truyền thống.

So sánh trực quan

Hình 13 biểu diễn trực quan Accuracy của các mô hình trong hai pipeline.

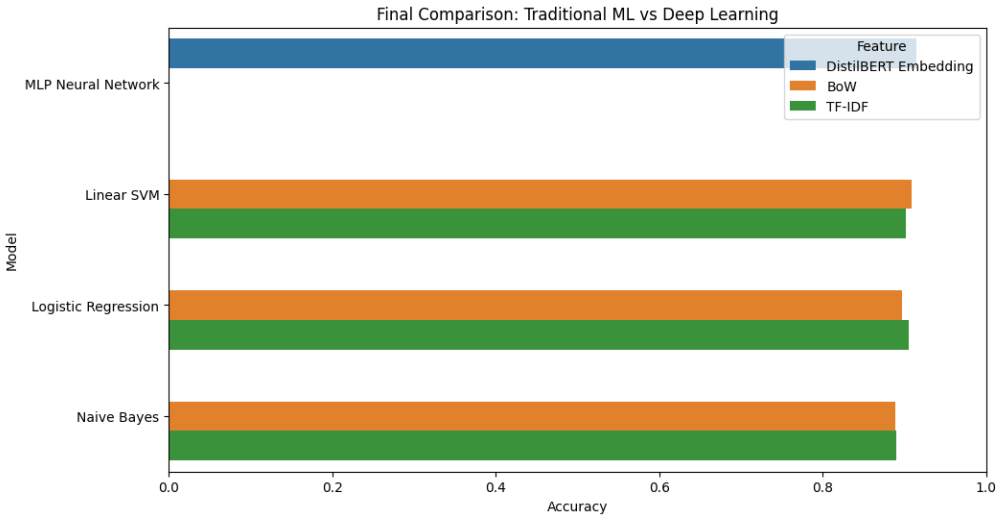

Figure 13: So sánh Accuracy giữa pipeline truyền thống và pipeline học sâu

Quan sát Hình 13, có thể thấy mô hình học sâu với đặc trưng **DistilBERT Embedding** đạt Accuracy cao nhất. Tuy nhiên, các mô hình truyền thống tuyến tính, đặc biệt là **Linear SVM** và **Logistic Regression**, cũng đạt kết quả rất cạnh tranh. Điều này cho thấy đối với bộ dữ liệu AG News, các đặc trưng truyền thống như BoW và TF-IDF vẫn đủ mạnh để phân loại văn bản tin tức khi được kết hợp với mô hình phù hợp.

So sánh mô hình tốt nhất của từng pipeline

Để đánh giá rõ hơn, nhóm so sánh trực tiếp mô hình tốt nhất của mỗi pipeline: **Linear SVM + BoW** đại diện cho pipeline truyền thống và **MLP Neural Network + DistilBERT Embedding** đại diện cho pipeline học sâu.

Table 15: So sánh mô hình tốt nhất của hai pipeline

Pipeline	**Mô hình tốt nhất**	**Đặc trưng**	**Accuracy**	**Macro F1**	**Training Time (s)**
Truyền thống	Linear SVM	BoW	0.9087	0.9085	1.4812
Học sâu	MLP Neural Network	DistilBERT Embedding	**0.9142**	**0.9142**	84.6330
Chênh lệch	–	–	**+0.0055**	**+0.0057**	**+83.1518**

Bảng 15 cho thấy pipeline học sâu đạt hiệu năng cao hơn pipeline truyền thống, nhưng đổi lại thời gian huấn luyện lớn hơn đáng kể. Cụ thể, mô hình MLP trên DistilBERT Embedding mất khoảng **84.63 giây** để huấn luyện, trong khi Linear SVM với BoW chỉ mất khoảng **1.48 giây**. Điều này cho thấy pipeline học sâu có chi phí tính toán cao hơn nhiều so với pipeline truyền thống.

Cần lưu ý rằng thời gian trong bảng chủ yếu phản ánh thời gian huấn luyện mô hình phân loại trên các đặc trưng đã có. Đối với pipeline học sâu, nếu tính cả thời gian trích xuất embedding bằng DistilBERT trên toàn bộ tập dữ liệu, chi phí xử lý thực tế sẽ còn cao hơn. Vì vậy, nhóm đã lưu sẵn embedding dưới định dạng `.npy` và tải lại từ Hugging Face trong notebook để giảm thời gian chạy lại trên Google Colab.

Phân tích theo chất lượng đặc trưng

Sự khác biệt quan trọng nhất giữa hai pipeline nằm ở cách biểu diễn văn bản.

Trong pipeline truyền thống, BoW và TF-IDF biểu diễn văn bản dựa trên tần suất xuất hiện của từ hoặc cụm từ. Các phương pháp này đơn giản, dễ hiện thực và có tốc độ xử lý nhanh. Tuy nhiên, chúng không hiểu được ngữ nghĩa sâu của văn bản. Ví dụ, các từ đồng nghĩa hoặc các cụm từ có ý nghĩa tương tự nhưng biểu diễn khác nhau vẫn có thể bị xem là các đặc trưng hoàn toàn riêng biệt.

Ngược lại, pipeline học sâu sử dụng DistilBERT Embedding để biểu diễn văn bản dưới dạng vector ngữ nghĩa. Các embedding này được học từ mô hình ngôn ngữ lớn đã được huấn luyện trước, do đó có khả năng nắm bắt tốt hơn quan hệ ngữ cảnh giữa các từ. Đây là lý do pipeline học sâu đạt kết quả cao nhất trong thí nghiệm.

Tuy nhiên, mức cải thiện của pipeline học sâu so với pipeline truyền thống không quá lớn. Nguyên nhân có thể đến từ đặc điểm của bộ dữ liệu AG News. Đây là bộ dữ liệu tin tức có bốn chủ đề khá rõ ràng, trong đó mỗi lớp thường chứa nhiều từ khóa đặc trưng. Ví dụ, lớp *Sports* có các từ như *game*, *team*, *win*; lớp *Business* có các từ như *market*, *stock*, *company*; lớp *Sci/Tech* có các từ như *software*, *technology*, *Microsoft*. Vì vậy, các phương pháp dựa trên tần suất từ như BoW và TF-IDF vẫn có thể phân loại rất hiệu quả.

Phân tích theo từng nhóm mô hình

Trong nhóm mô hình truyền thống, **Linear SVM** là mô hình đạt hiệu quả tốt nhất. Cấu hình **Linear SVM + BoW** đạt Accuracy 0.9087, cao hơn tất cả các mô hình truyền thống còn lại. Điều này phù hợp với đặc điểm của dữ liệu văn bản, vì sau khi vector hóa bằng BoW hoặc TF-IDF, dữ liệu thường có số chiều lớn và khá phù hợp với các mô hình tuyến tính.

Logistic Regression cũng cho kết quả tốt, đặc biệt khi kết hợp với TF-IDF. Cấu hình **Logistic Regression + TF-IDF** đạt Accuracy 0.9054, chỉ thấp hơn Linear SVM + BoW khoảng 0.33 điểm phần trăm. Tuy nhiên, thời gian huấn luyện của Logistic Regression cao hơn Linear SVM trong thí nghiệm này.

Naive Bayes có thời gian huấn luyện nhanh nhất, chỉ khoảng 0.03 đến 0.06 giây, nhưng Accuracy thấp hơn các mô hình còn lại. Điều này cho thấy Naive Bayes phù hợp làm baseline nhanh, nhưng giả định độc lập giữa các đặc trưng khiến mô hình khó đạt hiệu quả cao nhất trên bộ dữ liệu này.

Đối với pipeline học sâu, mô hình **MLP Neural Network** sử dụng DistilBERT Embedding đạt kết quả cao nhất. Điều này cho thấy embedding từ mô hình ngôn ngữ đã học được những biểu diễn hữu ích cho phân loại văn bản. Tuy nhiên, do nhóm chỉ huấn luyện MLP trên embedding đã trích xuất sẵn, mô hình chưa khai thác toàn bộ tiềm năng của DistilBERT như trong trường hợp fine-tuning end-to-end.

So sánh ưu điểm và hạn chế

Table 16: So sánh ưu điểm và hạn chế của hai pipeline

Tiêu chí	**Pipeline truyền thống**	**Pipeline học sâu**
Biểu diễn văn bản	Dựa trên tần suất từ hoặc trọng số TF-IDF. Đơn giản, dễ hiểu, dễ kiểm soát.	Dựa trên embedding ngữ nghĩa từ DistilBERT, có khả năng biểu diễn ngữ cảnh tốt hơn.
Hiệu năng phân loại	Cao, mô hình tốt nhất đạt Accuracy 0.9087.	Cao nhất trong thí nghiệm, đạt Accuracy 0.9142.
Chi phí huấn luyện	Thấp, Linear SVM + BoW chỉ mất khoảng 1.48 giây.	Cao hơn, MLP mất khoảng 84.63 giây, chưa tính thời gian trích xuất embedding.
Khả năng giải thích	Dễ giải thích hơn vì đặc trưng liên quan trực tiếp đến từ hoặc cụm từ.	Khó giải thích hơn vì embedding là vector ngữ nghĩa nhiều chiều.
Khả năng tái sử dụng	Dễ chạy lại, ít phụ thuộc tài nguyên phần cứng.	Cần lưu sẵn embedding hoặc có GPU để trích xuất đặc trưng nhanh hơn.
Phù hợp với dữ liệu AG News	Rất phù hợp do các lớp có nhiều từ khóa đặc trưng.	Phù hợp và cho kết quả tốt hơn, đặc biệt khi cần khai thác ngữ nghĩa sâu hơn.

Nhận xét tổng hợp

Kết quả thực nghiệm cho thấy cả hai pipeline đều đạt hiệu quả cao trên bộ dữ liệu AG News. Pipeline học sâu với **DistilBERT Embedding + MLP Neural Network** đạt kết quả tốt nhất với Accuracy và Macro F1 đều khoảng **91.42%**. Điều này chứng minh rằng đặc trưng ngữ nghĩa học sâu có thể cải thiện hiệu quả phân loại so với các phương pháp biểu diễn truyền thống.

Tuy nhiên, pipeline truyền thống vẫn cho kết quả rất cạnh tranh. Mô hình **Linear SVM + BoW** đạt Accuracy khoảng **90.87%**, chỉ thấp hơn pipeline học sâu khoảng **0.55 điểm phần trăm**, trong khi thời gian huấn luyện thấp hơn nhiều. Vì vậy, nếu ưu tiên tốc độ, tính đơn giản và khả năng triển khai nhanh, pipeline truyền thống là lựa chọn hợp lý. Ngược lại, nếu ưu tiên hiệu năng cao nhất và có đủ tài nguyên tính toán, pipeline học sâu là lựa chọn tốt hơn.

Từ các kết quả trên, nhóm lựa chọn **MLP Neural Network sử dụng DistilBERT Embedding** là mô hình có hiệu quả tốt nhất toàn bộ thí nghiệm. Đồng thời, **Linear SVM kết hợp với Bag of Words** được xem là baseline truyền thống mạnh, có hiệu năng cao và chi phí tính toán thấp. Sự so sánh này cho thấy việc lựa chọn pipeline cần phụ thuộc vào mục tiêu cụ thể: tối ưu hiệu năng hay tối ưu tài nguyên và thời gian xử lý.

6. Tổ chức và quản lý mã nguồn của nhóm

Bên cạnh việc xây dựng mô hình và đánh giá kết quả thực nghiệm, nhóm cũng tổ chức mã nguồn theo cấu trúc rõ ràng nhằm đảm bảo tính dễ đọc, dễ bảo trì và có khả năng tái lập kết quả. Toàn bộ mã nguồn được quản lý theo dạng repository, trong đó các thành phần chính như notebook, module xử lý, file đặc trưng và báo cáo được tách riêng thành từng thư mục.

Link của github: Machine_Learning_Assignment_252.git

Cấu trúc thư mục dự án

Cấu trúc thư mục của dự án được tổ chức như sau:

```
ML-Assignment-252/

 modules/
    models.py
    feature_extraction.py
    preprocessing.py
    utils.py

 notebooks/
    ML_pipeline.ipynb

 features/
    .gitattributes
    ft.zip
    ft_deeplearning.zip

 reports/
    ML_Report_252.pdf

 README.md
```

Cách tổ chức này giúp phân tách rõ ràng giữa mã nguồn chính, notebook thực nghiệm, dữ liệu đặc trưng đã trích xuất và báo cáo cuối cùng. Nhờ đó, quá trình kiểm tra, chạy lại notebook và mở rộng pipeline trong tương lai trở nên thuận tiện hơn.

Vai trò của các thư mục và file chính

Thư mục `modules/` chứa các file Python hỗ trợ cho quá trình xây dựng pipeline. Cụ thể, file `preprocessing.py` phụ trách các bước tiền xử lý văn bản như làm sạch dữ liệu, chuẩn hóa văn bản và loại bỏ stop words. File `feature_extraction.py` hiện thực các phương pháp trích xuất đặc trưng truyền thống như Bag of Words và TF-IDF. File `models.py` chứa phần định nghĩa và huấn luyện các mô hình học máy, bao gồm các mô hình truyền thống và mô hình mạng neural cho pipeline học sâu. File `utils.py` chứa các hàm tiện ích phục vụ việc tải dữ liệu, lưu kết quả, đánh giá mô hình và hỗ trợ tái sử dụng mã nguồn.

Thư mục `notebooks/` chứa notebook chính `ML_pipeline.ipynb`. Đây là file front-end chính của bài tập lớn, được sử dụng để chạy toàn bộ pipeline từ bước tải dữ liệu, tiền xử lý, trích xuất

đặc trưng, huấn luyện mô hình, đánh giá kết quả cho đến lưu báo cáo kết quả thực nghiệm. Notebook được thiết kế để có thể chạy trực tiếp trên Google Colab.

Thư mục `features/` chứa các file đặc trưng đã được trích xuất trước. Đối với pipeline truyền thống, file `ft.zip` chứa các đặc trưng Bag of Words và TF-IDF được lưu dưới định dạng `.npy`. Đối với pipeline học sâu, file `ft_deeplearning.zip` chứa các vector embedding được trích xuất từ DistilBERT. Việc lưu sẵn các đặc trưng này giúp giảm thời gian chạy lại notebook, đặc biệt trong môi trường Google Colab khi tài nguyên tính toán có giới hạn.

Thư mục `reports/` chứa báo cáo cuối cùng của bài tập lớn dưới dạng PDF, cụ thể là file `ML_Report_252.pdf`. Ngoài ra, trong quá trình chạy notebook, các kết quả thực nghiệm như bảng so sánh mô hình, kết quả pipeline học sâu và cấu hình huấn luyện cũng được lưu lại vào thư mục này nhằm phục vụ việc kiểm tra và đối chiếu kết quả.

File `README.md` đóng vai trò là tài liệu hướng dẫn chính của repository. File này trình bày thông tin môn học, giảng viên hướng dẫn, danh sách thành viên nhóm, mục tiêu bài tập lớn, cấu trúc thư mục, hướng dẫn chạy notebook, cũng như các liên kết liên quan đến Colab notebook, báo cáo PDF và các file đặc trưng đã trích xuất.

Quản lý file đặc trưng

Do quá trình trích xuất đặc trưng, đặc biệt là đặc trưng học sâu từ DistilBERT, có thể tốn nhiều thời gian và tài nguyên tính toán, nhóm đã lưu các đặc trưng đã trích xuất thành file nén và đưa lên nguồn công khai. Trong notebook, nếu các file đặc trưng chưa tồn tại trong môi trường Colab, chương trình sẽ tự động tải các file này về và giải nén để sử dụng.

Các liên kết tải đặc trưng được sử dụng gồm:

- Đặc trưng pipeline truyền thống: ft.zip
- Đặc trưng pipeline học sâu: ft_deeplearning.zip

Cách tổ chức này giúp notebook có thể chạy lại từ đầu mà không cần phụ thuộc vào Google Drive hoặc các dịch vụ lưu trữ cá nhân. Đồng thời, việc lưu đặc trưng dưới định dạng `.npy` giúp đảm bảo dữ liệu có thể được nạp nhanh bằng thư viện `NumPy` và sử dụng trực tiếp cho quá trình huấn luyện mô hình.

Hướng dẫn chạy notebook

Notebook chính của dự án được đặt tại:

`notebooks/ML_pipeline.ipynb`

Người dùng có thể chạy notebook trực tiếp trên Google Colab thông qua liên kết: Pipeline_NB

Khi chạy notebook, các bước chuẩn bị như cài đặt thư viện cần thiết, tải dữ liệu, tải file đặc trưng và giải nén đều được thực hiện trực tiếp trong môi trường Colab. Người dùng chỉ cần chọn `Runtime` → `Run all` để chạy toàn bộ quy trình. Việc thiết kế notebook theo hướng tự động hóa giúp đảm bảo khả năng tái lập kết quả và phù hợp với yêu cầu của bài tập lớn.

Ý nghĩa của việc tổ chức mã nguồn

Việc tổ chức mã nguồn theo cấu trúc thư mục rõ ràng mang lại nhiều lợi ích. Thứ nhất, các thành phần của pipeline được tách riêng, giúp dễ kiểm tra và chỉnh sửa. Thứ hai, các module xử lý có thể được tái sử dụng thay vì viết trực tiếp toàn bộ mã nguồn trong notebook. Thứ ba,

việc lưu kết quả và file đặc trưng theo thư mục riêng giúp quá trình quản lý thí nghiệm trở nên khoa học hơn.

Ngoài ra, việc quản lý mã nguồn trên GitHub giúp nhóm dễ dàng chia sẻ sản phẩm, theo dõi thay đổi và công bố kết quả thực nghiệm. Đây cũng là một bước quan trọng trong việc xây dựng một dự án học máy có tính hoàn chỉnh, minh bạch và có khả năng tái lập.

TÀI LIỆU THAM KHẢO

Nguồn tham khảo

[1] Xiang Zhang, Junbo Zhao, and Yann LeCun, *Character-level Convolutional Networks for Text Classification*, Advances in Neural Information Processing Systems 28 (NeurIPS), 2015. Bộ dữ liệu AG News được sử dụng trong các thí nghiệm phân loại văn bản của nghiên cứu này. Available at: https://arxiv.org/abs/1509.01626

[2] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake VanderPlas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay, *Scikit-learn: Machine Learning in Python*, Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. Available at: https://jmlr.org/papers/v12/pedregosa11a.html

[3] Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf, *DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter*, arXiv preprint arXiv:1910.01108, 2019. Available at: https://arxiv.org/abs/1910.01108